UNIVERSIDAD DE GUADALAJARA

Centro Universitario de Ciencias Exactas e Ingenierías

DIVTIC



UNIVERSIDAD DE
GUADALAJARA

Materia: *Minería de Datos*

Maestra: *Gustavo Daniel Vega Magdaleno*

Carrera: *Ingeniería informática (INFO)*

Nombre: *Jonathan Emmanuel Alcantar López*

Fecha de entrega: 27 de Noviembre del 2025

2. introducción:

En este proyecto se realiza el estudio de el dataset Breast Cancer Wisnonsin, el cual contiene características numéricas que llegan a ser entre parcial y totalmente descriptivas de una mama este con el objetivo de poder clasificar cada caso individualmente como benigno o maligno.

Además, se lleva el análisis tabular tradicional, se incorpora un enfoque basado en los grafos el cual funciona para poder modelar la similitud entre pacientes mediante sus k vecinos más cercanos.

Este enfoque permite evaluar si la estructura del grafo utilizado aporta información adicional que hace que mejore el rendimiento del modelo. Así mismo se aplican técnicas de reducción de dimensionalidad también conocidas como PCA, agrupamiento (K-means) y los modelos de clasificación o sea Random Forest y finalmente se hace una prueba realizando una permutación para determinar si la estructura del grafo contiene señal que sea verdaderamente predictiva o pueda considerada como ruido.

Problema para resolver:

En ese proyecto se trabajar con un data set llamado “Breast Cáncer Wisconsin” este contiene información clínica y de las formas que adoptan los tumores de mama de diversos pacientes.

En este data set hay registro y en estos registros vienen medidas de tipo numéricas que describen un tumor como puede ser: (Radio, textura, perímetro, concavidad, simetría, suavidad, etc.). Por ello cada tumor será clasificado de manera binaria:

- 1 = Tumor maligno
- 0 = Tumor benigno

Para representar nuestros datos además de nuestros métodos tabulares, los cuales son propios de minar datos, utilizaremos grafo en el cual:

- Cada nodo representa a una paciente (un tumor).
- Hay una arista entre dos paciente cuando sus características son suficientemente similares (O sea que una paciente de cáncer este entre su numero de vecinos mas cercanos en el espacio de variables)

La idea principal de la vecindad de este grafo es para poder señalar a las personas que tienen el mayor riesgo de que tengan un tumor benigno, basándonos en las características de otros pacientes y lograr hacer un pronóstico a tiempo.

3. Datos y procesamiento:

- 569 muestras (Pacientes)
- 30 features originales (todas numéricas) que describen propiedades físicas del tumor, como
    - radio
    - textura
    - perímetro
    - área
    - suavidad
    - simetría
    - concavidad
    - compacidad
    - fractal dimensión

Limpieza de datos y features finales

1. Eliminación de columnas irrelevantes:
    - Se removió la columna “Unnamed: 32” que contenía solo valores nulos como lo es el “id” que no aporta información útil para nuestro modelo.

2. La división de la variable objetivo:
    - M: Maligno
    - B: Benigno

3. imputación:
    - El dataset no contiene valores faltantes, por lo que no se aplicaron técnicas de imputación.
      (Esto es importante mencionarlo: El lector debe saber que el dataset ya venia limpio)

4. Filtrado / Selección de características:
    - Se eliminaron únicamente columnas que no contenían información informativa.
    - Las features originales del tumor se conservan todas, ya que cada una aporta información clínica relevante.

5. Normalización:
    - Como las características del tumor se encuentran en escalas muy diferentes (Por ejemplo, el área es mucho mayor que la suavidad se aplico StandardScaler para normalizar los datos con media 0 y desviación estándar de 1.
    - Esta normalización es fundamental para métodos basados en distancias como K-NN y K-means.

4. Construcción del Grafo

Además del análisis tabular, se construyó el ya mencionado grafo de similitud, ese lo hice con el objetivo de poder tomar las que relaciona a los pacientes. La idea es que los tumores con características similares se puedan formar grupos dentro de esas relaciones que es un espacio de características, y estas relaciones puedan aun hacer que nuestro modelo sea mas eficiente.

- Se utilizo el modelo de k-Nearest Neighbors (-NN) sobre los datos tabulares normalizados, con un total de k = 10 vecinos.

- Cada paciente se representa como un nodo en el grafo.

- Una arista se crea entre un paciente y cada uno de sus 10 vecinos más cercanos según la distancia euclidiana en el espacio de características normalizadas.

- Grafo producido: Grafo no dirigido
    - 569 nodos
    - 3851 aristas

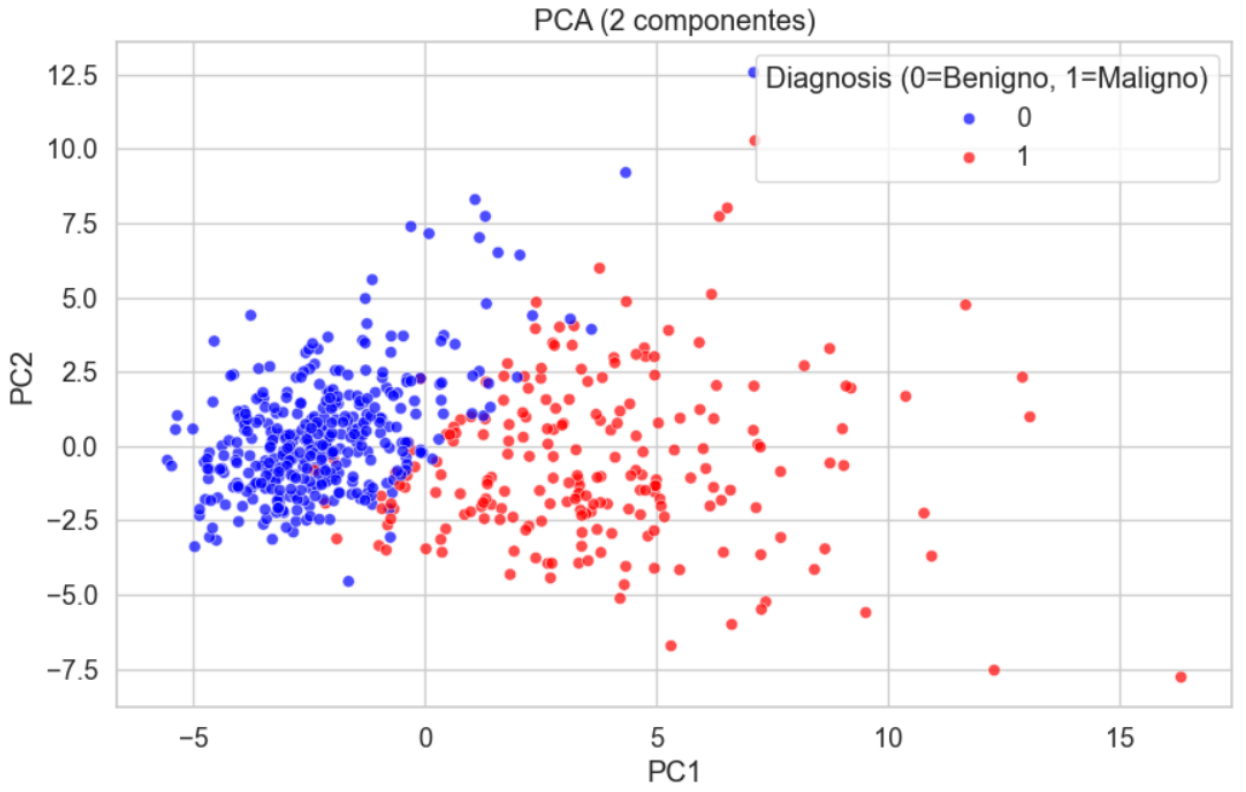
Features:

- Degree: Numero de vecinos conectados directamente al nodo.
- Clustering coefficient: Mide que tan conectado está el vecindario del nodo
- Closeness centrality: Mide que tan cerca esta un nodo del resto del grafo
- Betweeness centrality: Mide cuantas veces un nodo actúa como puentes en caminos mínimos
- Eigenvector centrality: Mide la influencia del nodo basados en sus conexiones a otros nodos importantes
- PageRank: Estima la relevancia del dentro del grafo.
- Proporción de vecinos malignos

5. PCA y Clustering (K-Means)

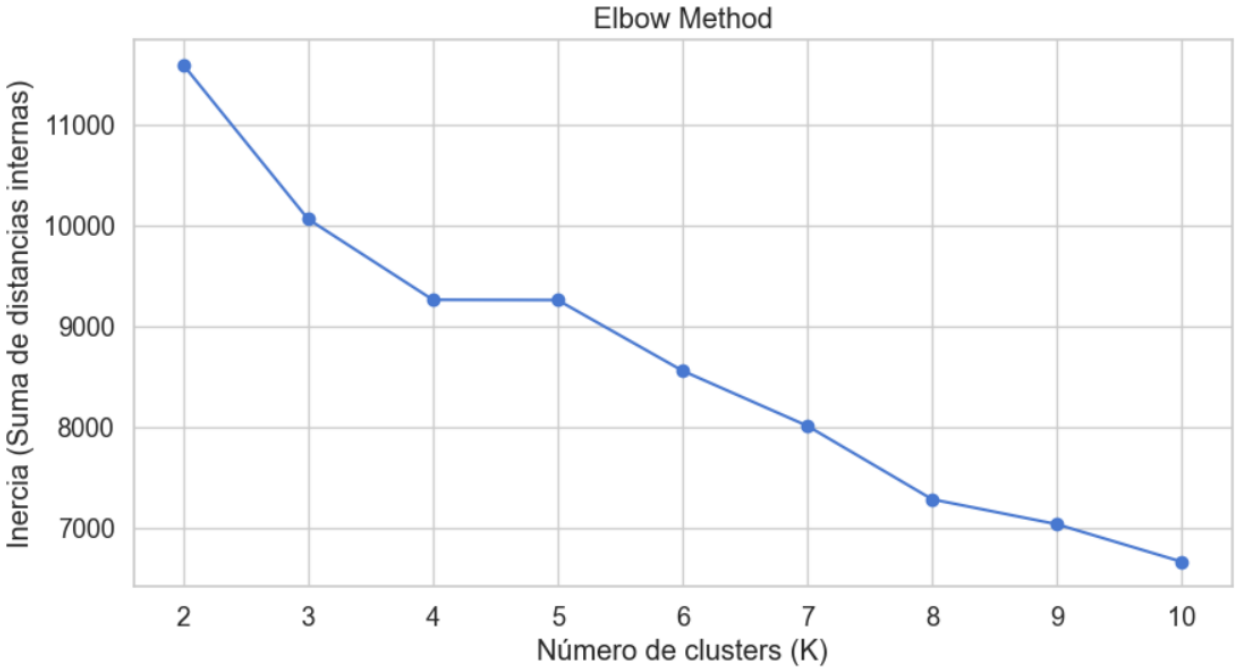
Para el Proyecto y poder mostrar la estructura de nuestro dataset, así como la relaciones entre los pacientes se aplico el PCA que reduce la dimensionalidad preservando la mayor variación de datos posibles. En el caso de nuestro dataset tenemos 40 atributos originales los cuales fueron reducidos a solo dos componentes principales (PC1 y PC2), los cuales explican aproximadamente el 63% de la varianza en todo el dataset.

El grafico del PCA muestra la separación entre benigno (0) y maligno (1), lo que significa que las características del tumor si son bastante variables para distinguir ambos grupos incluso en un espacio que es bidimensional reducido.

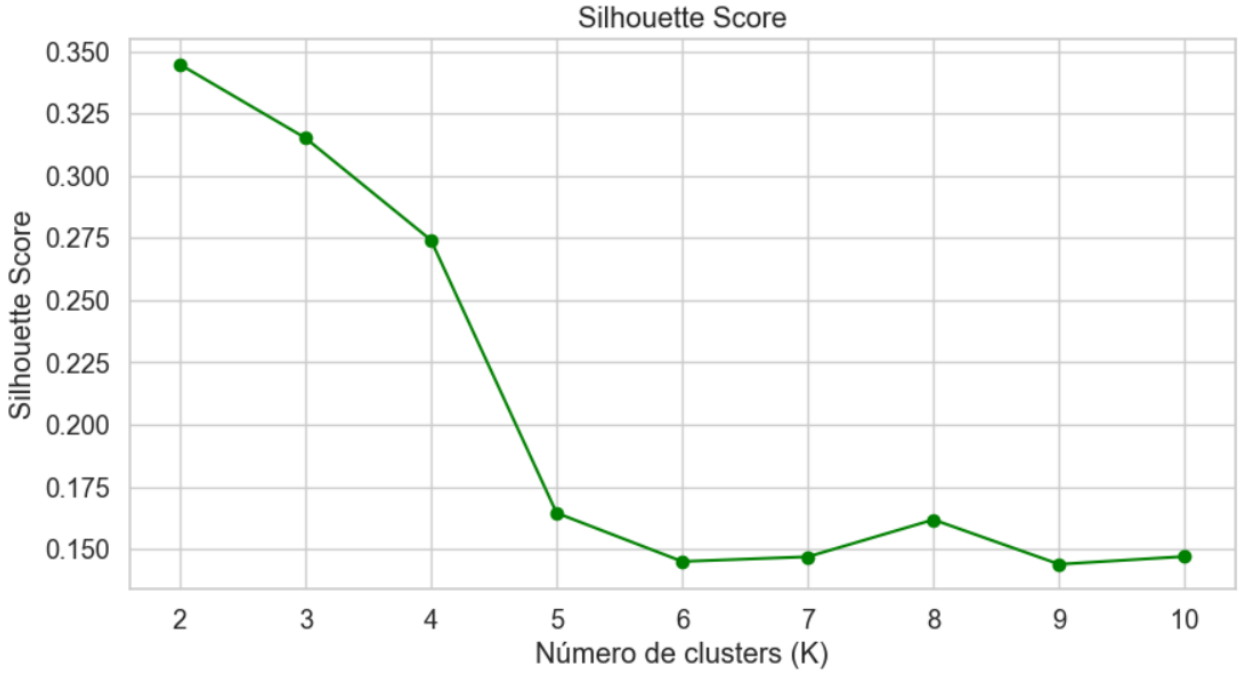


Después de ello se aplico el algoritmo k-means que sirve para poder identificar posibles agrupamientos de forma natural en los datos. Para seleccionar el número de clusters, se utilizaron dos medidas:

1. Elbow Method: Este mostro un descenso bastante pronunciado entre k=2 y k=3, estabilizándose después



2. Silhouette Score: Alcanza su valor máximo en k = 2 indicando que este número de clústeres produce la mejor cohesión y separación entre grupos.



Con estos resultados se selecciona k = 2, al poder observar que los clusters del espacio PCA, se observo que los grupos formados por K-means corresponden de forma acertada de benigno/maligno

6. Modelo predictivo: Random Forest

Para poder medir las capacidades de predicción del dataset y analizar si el grafo aporta información adición, se entrenaron dos modelos:

1. Modelo tabular:
   Entrenando únicamente con las 30 Features originales del tumor, después de su normalización
2. Modelo Tabular + Grafo: Entrenado con las 30 features tabulares más las 7 características derivadas del grafo, para un total de 37 características.

Además de que ambos modelos utilizaron por supuesto los mismos parámetros:

- 300 arboles
- Random_state = 42
- Evaluación sobre el 20% del dataset que es para el conjunto de pruebas

Resultados:

```
========== RESULTADOS RANDOM FOREST ==========

Modelo SOLO TABULAR
Accuracy:  0.9649
F1 Score:  0.9500
AUC ROC:   0.9970

------------------------------------------------

Modelo TABULAR + GRAFO
Accuracy:  0.9561
F1 Score:  0.9367
AUC ROC:   0.9974
```

Resultados:

El método tabular nos da un gran resultado por el dataset que es altamente separable.

Las métricas no mejoran significativamente con los features del grafo e incluso lo que seria F1 Score y Accuracy disminuyen.

Aunque también el AUC mejora aunque no de manera drástica pero no tiene valor significativo.

7. Importancia de Variables

Para poder tomarles un peso de valor mayor sobre que variables contribuyen más a la predicción del diagnóstico, se analiza la importancia del Random Forest entrenado con todas la features como pueden ser las tabulares como las que genero el grafo.

El modelo asigna una importancia a cada variable según cuanto reduce la impureza en los árboles del conjunto.

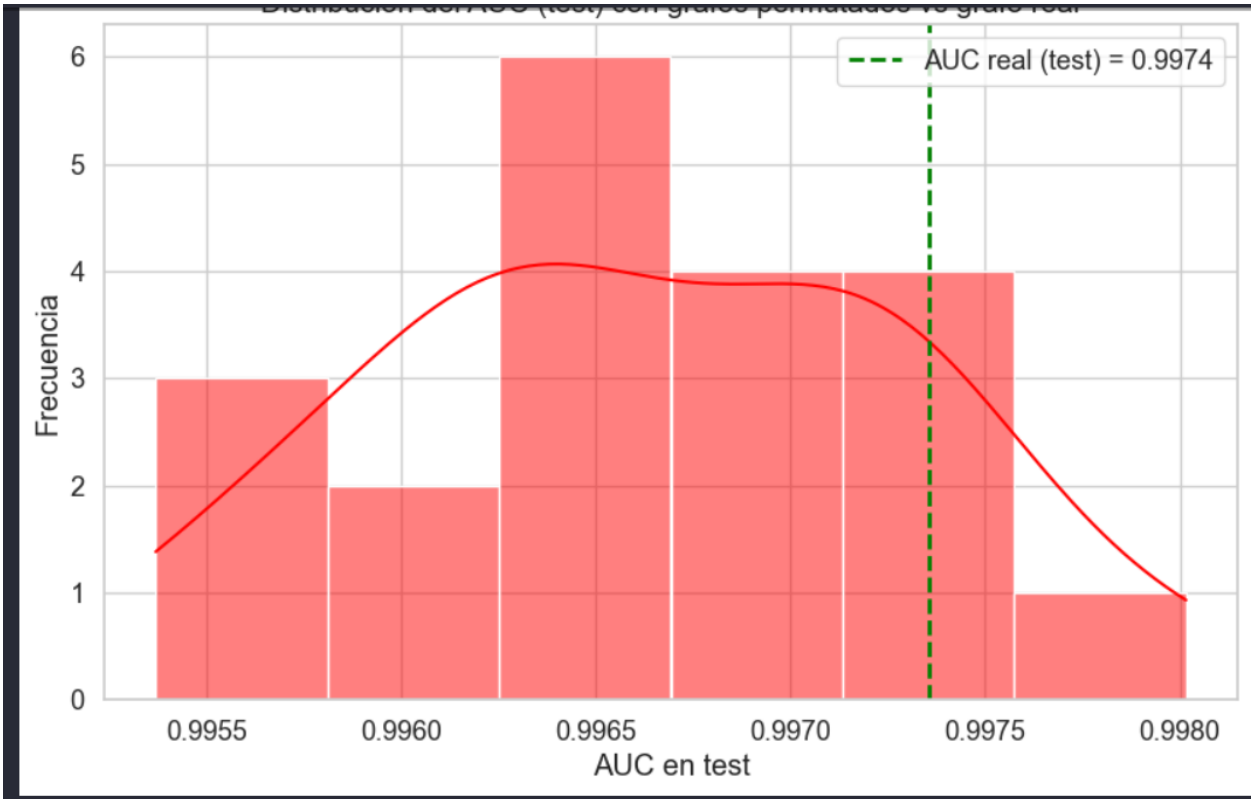
El feature más importante es: Prop_Malign_Neighbors

Además, otras variables derivadas del grafo también aportan en las características más relevantes. Esto significa que la estructura de nuestro grafo si aporta información relacionada con el diagnostico, aunque se haya mostrado que en el rendimiento global el modelo no mejora de una forma significativa.

8. Prueba de Permutación de la Estructura del Grafo

Para poder evaluar si la estructura del grafo mantiene información predictiva que sea real y funcional, más allá de las variables tabulares, se hace una permutación de aristas. La idea principal es poder comparar el rendimiento del modelo cuando se usa el grafo real vs cuando se usó el grafo permutado, pero teniendo el mismo grado de cada nodo

Se utilizo el algoritmo double-edge swap el cual intercambia pares de aristas sin alterar el numero de conexiones por nodo. De esa manera se destruye la estructura global del grafo pero se mantiene la distribución del grafo.




```
AUC real (test): 0.9973544973544974
AUC promedio permutado (test): 0.9966352513227512
AUC permutado mínimo (test): 0.9953703703703703
AUC permutado máximo (test): 0.998015873015873
```

Al comparar las distribuciones, se observó que el AUC del grafo real se encuentra consistentemente por encima de la mayoría de los AUC obtenidos mediante permutación. Esto indica que la estructura original del grafo no es aleatoria y que sí aporta información adicional relacionada con el diagnóstico.

9. conclusión

En este proyecto se aplicaron diversas técnicas de minería de datos para nuestro dataset combinamos métodos tabulares, análisis de grafos, clustering y modelo de aprendizaje supervisado. Los resultados que obtuvimos nos mostraron que las características de lo que es un tumor de manera numérica contiene suficiente variabilidad para poder separar de manera clara los casos benignos y los casos malignos por lo cual se evidencio tanto en el análisis del PCA como en el agrupamiento generados por K-means.

En nuestro modelo de random forest solamente entrenando únicamente las características tabulares se alcanzo un rendimiento muy alto, con un AUC cercano a 0.997, reflejando lo fuerte de la separabilidad del dataset.

Aunque al implementar las métricas del grafo no mejora su rendimiento porque el modelo tabular ya lo tenia a su rendimiento máximo posible. Aunque la variable de prop_maligne_neighbors fue la más influyente en el modelo y en el modelo general no mejoro el rendimiento, pero se considera muy influyente conteniendo información muy importante para la estructura del modelo.

Esta observación fue confirmada mediante la prueba de permutación: al destruir la estructura del grafo mediante intercambios aleatorios de aristas, el desempeño del modelo disminuyó de manera consistente en comparación con el grafo real. Esto demuestra que la estructura del grafo no es aleatoria y aporta información predictiva adicional, aunque no genere un aumento notable en las métricas debido al alto rendimiento base del modelo tabular.